Sadržaj

Projektna Dokumentacija — Lumen DS Cross-Sell & Up-Sell Sustav za Preporuke **1**
Sadržaj . . . 1
1. Razumijevanje poslovanja . . . 1
2. Razumijevanje podataka . . . 2
3. Priprema podataka . . . 5
4. Modeliranje . . . 7
5. Evaluacija . . . 11
6. Implementacija (Deployment) . . . 13
Dodatak — Sažetak izlaza pipelinea . . . 15

Projektna Dokumentacija — Lumen DS Cross-Sell & Up-Sell Sustav za Preporuke

Metodologija: CRISP-DM (Cross-Industry Standard Process for Data Mining)

Ovaj dokument opisuje cjelokupni proces data science-a u okviru natjecateljskog projekta Lumen DS — od razumijevanja poslovnog problema do implementacije (deployment) API-ja za preporuke u stvarnom vremenu. Nadopunjuje operativne dokumente README.md i RUN_BOOK.md, koji se fokusiraju na *kako pokrenuti* pipeline; ovdje dokumentiramo *što smo izgradili i zašto*.

Sadržaj

1. Razumijevanje poslovanja
2. Razumijevanje podataka
3. Priprema podataka
4. Modeliranje
5. Evaluacija
6. Implementacija (Deployment)

---

1. Razumijevanje poslovanja

1.1 Zašto su Cross-Sell i Up-Sell važni

Monetizacija baze kupaca jedna je od aktivnosti s najvećim polugom u B2B distribuciji. Istraživanja industrije dosljedno pokazuju da:

- **Akvizicija novog kupca košta 5–25× više od zadržavanja postojećeg.** Postojeći kupci već vjeruju brendu, integrirani su u procese nabave i imaju račun u ERP sustavu — što novi potencijalni kupac ne posjeduje.
- **Vjerojatnost prodaje postojećem kupcu iznosi 60–70%, naspram 5–20% za novog prospekta.** Čak i skromno poboljšanje stope uspješnosti cross-sell-a kumulativno se pretvara u značajan rast prihoda.
- **Up-selling postojećih kupaca prema proizvodima višeg razreda povećava prosječnu vrijednost narudžbe bez povećanja troškova akvizicije.** To izravno poboljšava bruto maržu po odnosu s kupcem.

Za B2B distributera s ~12.000 aktivnih računa, pitanje nije *treba li* investirati u cross-sell i up-sell, već *koji kupac treba dobiti koji proizvod i kada*.

1.2 Cilj projekta

Izgraditi sustav za preporuke temeljen na podacima koji:

1. **Segmentira kupce** u bihevioralne grupe (buyer persone) kako bi se preporuke mogle personalizirati za svaki segment.
2. **Otkriva asocijacije između proizvoda** u povijesnim transakcijskim podacima kako bi se identificiralo koji se proizvodi često kupuju zajedno.
3. **Poslužuje preporuke u stvarnom vremenu** putem REST API-ja koji tim prodaje ili e-commerce front-end može pozvati kada je kupac na telefonu ili na naplatnom mjestu. Potrebne su dvije endpoint-točke:

- `POST\/cross-sell` — za zadanog kupca (i opcionalno proizvode koji se trenutno naručuju), preporuči dodatne grupe proizvoda koje vjerojatno želi kupiti.
- `POST\/up-sell` — za specifične proizvode koje kupac kupuje, preporuči alternative višeg razreda unutar iste grupe proizvoda.

1.3 Kriteriji uspjeha

Dimenzija	Cilj	Razlog
Kvaliteta segmentacije	Silhouette score interpretabilan, segmenti bihevioralno distinktni	Tim prodaje mora moći djelovati na temelju segmenata
Rangiranje cross-sell-a	ROC-AUC ≥ 0.85 bez vremenskog leakage-a (curenja informacija)	Kvaliteta rangiranja važnija je od apsolutne preciznosti u uvjetima neravnoteže 290:1
Up-sell signal	Pozitivan dokaz rasta cijene u hold-out validacijskom prozoru	Ne možemo provesti A/B test, pa je proxy temeljen na naprednom vremenu najbolji raspoloživi dokaz
API latencija	Ispod sekunde po pozivu, svi artefakti u memoriji	API se poziva tijekom aktivnih prodajnih razgovora
Reproducibilnost	Fiksni seedovi, dokumentiran vremenski raspon	Ponovni pokret mora producirati identične artefakte

1.4 Ograničenja i pretpostavke

- **Podaci su jedini izvor istine.** Nije dostupan domenski stručnjak koji bi označio "ovo je cross-sell par" — asocijacije se moraju ekstrahirati iz povijesti transakcija.
- **Dataset je B2B.** To je empirijski utvrđeno u §2.4 i oblikuje svaki modelarski izbor (košarica na razini kupca, rangiranja uvjetovana segmentom, fokus na ključne račune).
- **Nije dostupna A/B test infrastruktura.** Validacija se mora oslanjati na vremenski hold-out (treniraj na prošlosti, evaluiraj na budućnosti), a ne na eksperimentalne grupe tretmana i kontrole.
- **API mora biti jednostavan.** Prema projektnom zadatku: dvije endpoint-točke koje primaju `CustomerID` i listu proizvoda, a vraćaju rangirane preporuke s ocjenama pouzdanosti.

---

2. Razumijevanje podataka

2.1 Izvorni dataset

Svojstvo	Vrijednost
Naziv datoteke	`LUMEN_DS.csv`
Kodiranje	UTF-16, pipe-odvojen, ~795 MB
Redovi	~1.300.000 stavki faktura
Stupci	32 sirova polja koja pokrivaju dimenzije kupca, proizvoda, transakcije, financija, prodajnog kanala i proizvodnje
Granularnost	Jedan red po stavci fakture (jedan proizvod na jednoj fakturi)

2.2 Stupci korišteni u pipelineu

Sirovi dataset ima 32 stupca, ali modelarski pipeline koristi samo fokusirani podskup. Tablica u nastavku navodi svaki stupac koji je stvarno pročitan u barem jednoj bilježnici, zajedno s ulogom koju ima. Stupci koji nisu navedeni ne koriste se ni u jednom modelu — sažeti su u §2.3.

> *"Gdje se koristi" odnosi se na produkcijski pipeline: `01\data_cleaning`, `02\customer_segmentation`, `03\market_basket`, `04\cross_sell_recommender`, `05\upsell_model`. Dvije bilježnice u mapi `notebooks\archive\` su istraživačke i nisu dio API puta — vidi §3.7 i §4.3.1.*

Stupac	Gdje se koristi	Uloga u projektu
`CustomerID`	Sve bilježnice	Primarni ključ za svaku analizu na razini kupca (RFM, segmentacija, grupiranje košarica, preporuke).
`Invoice\Date`	Sve bilježnice	Recency u RFM-u (segmentacija), ključ košarice kupac-mjesec (market basket), granična vrijednost raspodjele trening/label (cross-sell, up-sell), izračun trajnosti (cross-sell).
`Invoice\#`	Segmentacija, market basket, cross-sell	Frequency u RFM-u; jedinica ko-pojavljivanja košarice na razini fakture (korištenjem za potvrdu da su košarice na razini fakture prerijetke i prelazak na kupac-mjesec); značajka `train_orders` za cross-sell model.
`Invoiced\price`	Čišćenje, segmentacija, cross-sell, up-sell	Monetary u RFM-u (s količinom); imputira se gdje ≥ 50% redova nekog proizvoda ima valjane cijene; prosječna cijena proizvoda za klasifikaciju razreda (up-sell); značajka `pg_avg_price` (cross-sell).
`Invoiced\qty\(shipped)`	Čišćenje, segmentacija, cross-sell	Množi se s `Invoiced\price` za izračun `line_revenue` (Monetary, `train_revenue`, `pg_avg_revenue`). Negativni ili nulti redovi se filtriraju pri čišćenju.
`Item\Code`	Čišćenje, market basket (bonus pokretanje na razini stavke), cross-sell, up-sell	Identifikator proizvoda; značajka `train_items`; ciljna varijabla za klasifikaciju razreda; razina preporuke stavke Level-2 unutar API-ja. Kodovi `SAMPLE` i oni s prefiksom `/` se filtriraju pri čišćenju.
`Product\group`	Market basket, cross-sell, up-sell	Granularnost preporuke za cross-sell ranker; jedinica ko-pojavljivanja na razini košarice; medijan cijene na PG razini za up-sell određivanje razreda.
`GM%`	Čišćenje, cross-sell	Ponovo se izračunava iz cijene i troška gdje su oba dostupna; winsorize (ograničavanje ekstremnih vrijednosti) na `{[}-5,\1{]}`; značajke `train_avg_gm` i `pg_avg_gm`.
`Customer\Region`	Cross-sell	Label-enkodiran → značajka `region_enc`.
`Customer\industry`	Cross-sell	Label-enkodiran → značajka `industry_enc`.
`Top\Customer\Group`	Cross-sell	Label-enkodiran → značajka `top_group_enc`.
`Customer\First\Invoice\Date`	Cross-sell	Pokreće značajku `tenure_days` (datum snapshota − prva faktura).
`Cost\of\part`	Čišćenje	Koristi se za oporavak `GM%` gdje je null; za filtriranje “smeće” redova gdje `Cost\\TU\textgreater{}\20\×\Invoiced\price`. Ne koristi se izravno kao značajka.

Stupac	Gdje se koristi	Uloga u projektu
`Intercompany`	Čišćenje	Filter pre-modeliranja: redovi s `Intercompany\=\YES` (intrakorporativni prijenosi) uklanjaju se prije bilo koje analize.

Uz to, izvedeni stupac `Cluster_name` (izlaz segmentacije) hrani oba nizvodna preporučitelja: kao značajka `cluster_enc` u cross-sell modelu, i kao ključ personalizacije za popularnost stavki uvjetovanu klasterom u up-sell modelu.

2.3 Nekorišteni stupci

Svaki drugi stupac u sirovom datasetu ispušta se rano pri čišćenju ili se jednostavno nikad ne čita. Tablica u nastavku bilježi što je isključeno i zašto — čuvajući transparentnost revizije umjesto impliciranja da je svako polje bilo obrađeno.

Stupac	Razlog nekorištenja
`Invoice\Line\#`	Metapodatak pozicije unutar fakture; irelevantan nakon agregacije na razini fakture ili kupac-mjesec; gotovo jednako jedinstvenih vrijednosti kao i redova.
`Order\#`, `Order\Date`, `Order\Line\#`	Artefakti strane narudžbe PO ciklusa; `Invoice\Date` je kanonska vremenska oznaka za RFM i vremensku raspodjelu.
`Ordered\qty`	Koristi se samo kao provjera zdravog razuma pri čišćenju; kanonski signal "kupac je ovo kupio" jest `Invoiced\qty\(shipped)`.
`Material\cost`, `Labor\cost`, `Overhead\cost`	Komponente `Cost\of\part`; agregat je dovoljan za naša pravila čišćenja.
`Invoiced\price\(TX)`	Semantika polja je nejasna (vjerojatno porezna varijanta); isključena kako bi se izbjeglo uvođenje šumnih značajki.
`Sales\Channel\-\Internal`, `Sales\Channel\-\External`, `Sales\Channel\-\Grouping`	Metapodaci atribucije kanala; nisu značajka na razini kupca ili proizvoda relevantna za "što bi ovaj kupac sljedeće trebao kupiti."
`Make\vs\Buy`	Atribut s ponudbene strane (izrađeno interno ili nabavljeno); nije prediktivan za cross-sell ponašanje.
`Manufacturing\Region`, `Manufacturing\Location\Code`	Gdje se stavka proizvodi — ponudbena, ne kupčeva strana, pa irelevantno za cross-sell i up-sell.
`Product\family`	Zamijenjeno s `Product\group`, koji je odabrana granularnost košarice i preporuke.
`Born\on\date`, `Price\last\modified\date\in\the\ERP`	Metapodaci životnog ciklusa stavke / ažuriranja cijene; nema očekivanog signala za cross-sell ili up-sell.
`#\of\unique\products\on\a\quote`	Metrika na razini ponude, nije usklađena s granularnošću stavke fakture u datasetu.

2.4 Utvrđivanje B2B prirode dataseta

Zadatak ne označava dataset eksplicitno, ali svaki strukturni i statistički signal upućuje na **B2B proizvodnju ili industrijsku distribuciju**:

Strukturni signali (shema): - Zastavica `Intercompany` — ima smisla samo kada prodaja može biti intrakorporativna. - `Customer\industry` (npr. `IC000`, `IC001`) — B2C kupci nemaju "industriju." - `Make\vs\Buy`, `Cost\of\part`, `Manufacturing\Location\Code` — rječnik proizvodnje. - `Top\Customer\Group`, `Customer\First\Invoice\Date` — terminologija upravljanja ključnim računima. - Odvojenost `Ordered\qty` i `Invoiced\qty\(shipped)` — klasičan B2B PO ciklus s djelomičnim isporukama. - 6-znamenkasti numerički `CustomerID` — tipično za SAP/Oracle/JDE matičnu datoteku kupaca.

Statistički signali (nakon filtriranja Intercompany=YES): - **11.775 jedinstvenih kupaca** — reda tisuća, ne milijuna. - **Medijan prihoda kupca ≈ $6.737, P90 ≈ $211.738, maksimum ≈ $1,15B.** Omjer max/medijan od ~171.000× nemoguć je u

B2C kontekstu. - **Medijan 5 stavki fakture po kupcu, P90 ≈ 87 stavki** — bimodalna distribucija: dugi rep malih povremenih kupaca + manjina velikih korporativnih računa s tisućama stavki godišnje.

Ovaj zaključak pokreće nekoliko modelarskih odluka: košarice na razini kupca (ne fakture), segmentacija RFM-om koji je osjetljiv na "kitove" (whale kupce), i rangiranja uvjetovana klasterom.

2.5 Početni nalazi o kvaliteti podataka

Istraživačka analiza identificirala je šest klasa problematičnih podataka koje su morale biti riješene prije modeliranja:

1. **Privremeni `CustomerID -99`.** NULL marker izvornog sustava, nije pravi kupac.
2. **Kodovi stavki s prefiksom `SAMPLE` i `/`.** Tehnički zapisi i besplatni uzorci — nisu stvarne kupovine.
3. **Nulta / null `Invoiced\price`.** ~9% redova. Mješavina tehničkih artefakata i oporavljenih vrijednosti.
4. **Negativna `Invoiced\price` i negativne količine.** Kreditne note / povrati — mali po volumenu, ali iskrivljuju RFM.
5. **`Cost\of\part` `Invoiced\price`.** Nekoliko redova gdje je trošak bio 20× viši od cijene — jasno smeće.
6. **Outlieri u `GM%`.** Repne vrijednosti do −1000+ i nekolicina iznad 1.0 — potrebno winsorize (ograničavanje ekstremnih vrijednosti).

Kodovi uzoraka/slash stavki samo su iznosili stotine tisuća redova; `Intercompany=YES` uklonio je još jedan veliki blok. Oni su kvantificirani u §3.

---

3. Priprema podataka

Pipeline čišćenja izvodi se u potpunosti u `notebooks/data_cleaning.ipynb`. Svaka odluka donesena je namjerno, s obrazloženjem navedenim u nastavku.

3.1 Popravak kodiranja i početno ispuštanje stupaca

Prvi korak bilježnice pretvara sirovu `LUMEN_DS.csv` iz UTF-16 → UTF-8 i uklanja ugrađene dvostruke navodnike koji bi inače slomili parser za pipe format. Rezultat se sprema u cache kao `data/raw/data.csv` kako bi se konverzija preskočila pri sljedećim pokretanjima. Zatim se ispušta 11 stupaca jer su redundantni ili previše granularni za bilo koji od planiranih modela:

Ispušteni stupac	Razlog
`Invoice\Line\#`	Redoslijed unutar fakture — irelevantan za preporuke
`Order\Date`, `Order\Line\#`, `Order\#`	`Invoice\Date` je kanonska vremenska oznaka
`Material\cost`, `Labor\cost`, `Overhead\cost`	Agregirani u `Cost\of\part`
`Sales\Channel\-\Grouping`	Redundantno s `Sales\Channel\-\Internal/External`
`Born\on\date`,	Metapodaci životnog ciklusa stavke, ne prediktivno za
`Price\last\modified\date\in\the\ERP`	cross-sell
`#\of\unique\products\on\a\quote`	Metrika na razini ponude, ne fakture

3.2 Filter za Intercompany

Redovi s `Intercompany=YES` predstavljaju intrakorporativne prijenose, a ne stvarne transakcije kupaca. Filtrirani su prije bilo koje druge analize kako bi se izbjeglo zagađivanje RFM i statistike košarica.

3.3 Odluke o čišćenju na razini reda

3.3.1 Ispuštanje privremenog `CustomerID -99` NULL marker izvornog sustava. Uklanjanje ovih redova je nedvosmisleno.

3.3.2 Ispuštanje kodova stavki s prefiksom `SAMPLE` i `/` Ovo su besplatni uzorci (nisu tražene kupovine) i tehnički zapisi izvornog sustava. Pojavljuju se na stotinama tisuća stavki i stvorili bi lažne signale ko-kupovine. Filter:

```
Item Code ~ "SAMPLE" or Item Code starts with "/"
```

3.3.3 Obrada nulte / null `Invoiced\price` Otprilike 9% redova imalo je nultu ili null cijenu. Dvije opcije: ispustiti ili imputirati. Odabrali smo strategiju **imputacije temeljene na pragu**:

- Za svaki `Item\Code`, izračunaj udio njegovih redova koji imaju pozitivnu cijenu.
- Ako ≥ 50% redova nekog proizvoda ima valjanu cijenu (odabrano analizom osjetljivosti na pragovima 10/30/50/70/90%), imputa se null/nulte redove s **medijanom pozitivnih cijena za taj proizvod**.
- Ako < 50% redova nekog proizvoda ima valjanu cijenu, proizvod je previše nepouzdan za imputaciju — ispusti te redove.

Ovo balansira zadržavanje podataka naspram kontaminacije. Prag od 50% čuva većinu oporavljenih redova isključujući pritom stavke gdje je polje cijena uglavnom pokvareno.

3.3.4 Ispuštanje negativne `Invoiced\price` Redovi s negativnom zaračunatom cijenom su kreditne note (povrati / refundacije). Uključivanje ih kao "kupovine" iskrivilo bi Monetary i signale košarica.

3.3.5 Ispuštanje negativnih količina; izdvajanje redova s nultom isporukom

- Negativni `Invoiced\qty\(shipped)` i negativni `Ordered\qty` su povrati — ispuštaju se.
- Redovi s `Invoiced\qty\(shipped)\==\0` izdvojeni su u sporedni dataframe (namjera-ali-nije-isporučeno) ali se ne koriste nizvodnje jer je kanonski signal "kupac je ovo kupio" isporučena količina veća od nule.

3.3.6 Ispuštanje "smeće" redova troška Redovi gdje je `Cost\of\part\\TU\textgreater{}\20\×\Invoiced\price` su greške unosa podataka (npr. pogrešna konverzija jedinice). Iskrivljuju `GM%` prema ekstremno negativnim vrijednostima. Filter je konzervativan — sve što je 20× cijene je jasno pokvareno; legitimne stavke s niskom maržom nisu pogođene.

3.3.7 Winsorize `GM%` na `{[}-5,\1{]}` Nakon popravka smeće redova troška vs. cijene, rezidualna distribucija `GM%` još uvijek ima dugi lijevi rep i nekoliko vrijednosti iznad 1.0 (rubni slučajevi gdje je cijena = 0 koji su izbjegli ranije filtere). Isjecanje na `{[}-5,\1{]}` zadržava smjer signala eliminiranjem šuma.

3.4 Imputacija kategorijalnih null vrijednosti

Sljedeći stupci se popunjavaju doslovnim nizom `\XeTeXglyph\numexpr\XeTeXcharglyph"0027\relax{}Unknown\XeTeXglyph\numexpr\XeTeXcharglyph"0027\relax{}`:

```
Manufacturing Region, Manufacturing Location Code, Intercompany,
Customer industry, Customer Region, Top Customer Group,
Product family, Product group, Make vs Buy,
Sales Channel - Internal, Sales Channel - External
```

Obrazloženje: `\XeTeXglyph\numexpr\XeTeXcharglyph"0027\relax{}Unknown\XeTeXglyph\numexpr\XeTeXcharglyph"0027\relax{}` postaje vlastita kategorija u label enkodiranju, čuvajući "odsutnost" kao značajku umjesto tihog uvođenja nevjerojatnih vrijednosti imputacijom modusom.

3.5 Oporavak GM% gdje je moguće

Gdje je `GM%` bio null, ali su bili prisutni i `Invoiced\price\≠\0` i `Cost\of\part`, GM% je reizračunat iz prvih načela:

```
GM% = (Invoiced price - Cost of part) / Invoiced price
```

Ovo oporavlja značajan udio redova. Preostali null `GM%` ostaje kakav jest — tim redovima nedostaje jedan od ulaza (tipično je `Cost\of\part` null za sve redove određene stavke, pa ne postoji izvor za imputaciju).

3.6 Konačni čisti dataset

Izlaz pipelinea (`data/processed/data_clean_final.csv`) je kanonski ulaz za **svaku nizvodnu bilježnicu**. Koraci čišćenja smanjuju dataset s ~1,3M sirovih stavki faktura na **~930K redova** zadržanih za modeliranje. Nakon gore navedenih koraka:

- Svi ključni identifikatori (`CustomerID`, `Item\Code`, `Invoice\Date`, `Invoiced\price`) su popunjeni.
- Sve cijene su ≥ 0 i sve količine su > 0.
- `GM%` je ograničen na `{[}-5,\1{]}`.

- Kategorijalni null-ovi su eksplicitne `\XeTeXglyph\numexpr\XeTeXcharglyph"0027\relax{}Unknown\XeTeXglyph\numexpr\XeTeXcharglyph"0027\relax{}` vrijednosti.

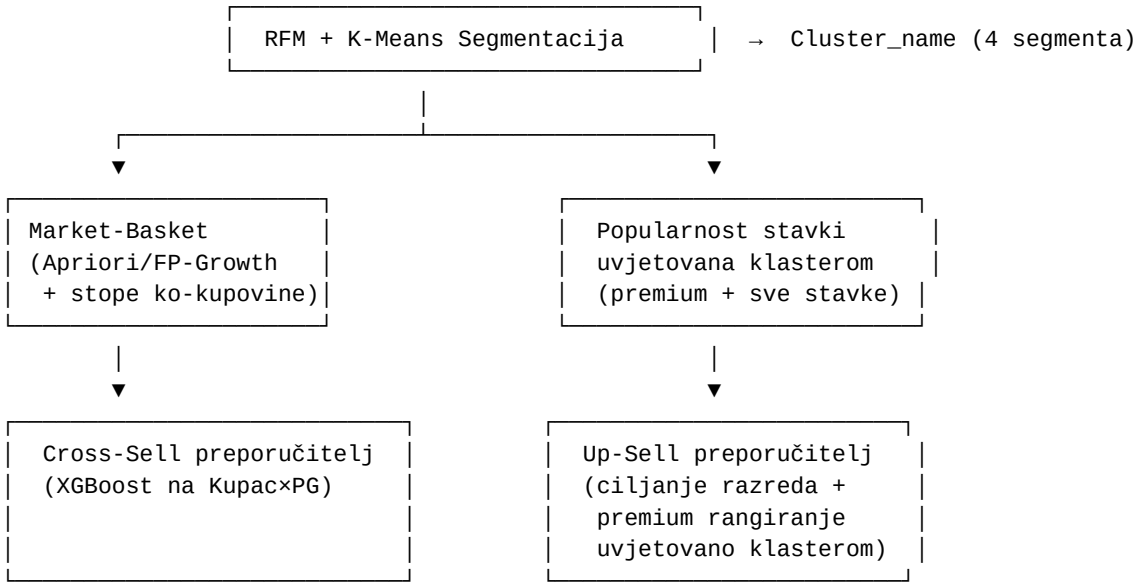
3.7 Arhivirana istraživanja — `encoding_and_feature_engineering.ipynb`

Ranija bilježnica (`notebooks/archive/encoding_and_feature_engineering.ipynb`) label/one-hot enkodirala je čisti dataset i producirala enkodiranu datoteku s 928k redova i tablice agregata na razini kupca. Bila je korisna kao istraživački korak — potvrđujući distribucije značajki i agregate — ali produkcijski pipeline **ne ovisi** o njoj: svaka nizvodna bilježnica ponovo čita `data_clean_final.csv` i gradi značajke koje treba interno. Arhivirana bilježnica čuva se radi transparentnosti ali nije dio API puta.

---

4. Modeliranje

Sustav za preporuke ima tri modelarska komponente koje se nadograđuju jedna na drugu:



Svi vremenski modeli koriste fiksnu raspodjelu:

- **Trening period:** fakture prije **2019-07-01** (~2,5 godina povijesti)
- **Label window (period oznake):** fakture od **2019-07-01 do 2020-07-01** (12-mjesečni napredni prozor)

Nasumični seedovi su fiksirani (`random_state=42`) na svakom modelu i na SMOTE-u.

4.1 Segmentacija kupaca — RFM + K-Means

Bilježnica: `notebooks/customer_segmentation.ipynb`.

4.1.1 Izračun RFM-a Datum snapshota: **2020-07-01** (jedan dan nakon maksimalnog datuma fakture u čistom datasetu).

Po kupcu: - **Recency** — dani od kupčeve posljednje fakture do datuma snapshota (niže je bolje) - **Frequency** — broj distinktnih faktura u kupčevoj povijesti - **Monetary** — zbroj `Invoiced\price\×\Invoiced\qty\(shipped)` kroz kupčevu povijest

Izlaz: 11.753 kupaca s potpunim RFM ocjenama.

4.1.2 RFM ocjene (1–5) i segmenti temeljeni na pravilima Svaka od R, F, M binira se u kvintile pomoću `pd.qcut` (Recency obrnuto: niže je bolje → ocjena 5). Kupci se zatim dodjeljuju čitljivom segmentu na temelju kanonskog R-F mapiranja (Champions, Loyal, At Risk, Hibernating, itd.). Ove oznake temeljene na pravilima čuvaju se kao opisni stupci uz K-Means klaster.

4.1.3 K-Means klasteriranje Ulazi su log-transformirani (`log1p`) i standardizirani (`StandardScaler`) kako bi se komprimirali teški desni repovi u Frequency i Monetary vrijednostima.

Odabir K: analiza lakta + silhouette za `K\␣\{[]2,\7{]}` (`n_init=10`, `random_state=42`). K=4 odabran je kao najbolji kompromis između silhouette score-a i interpretabilnosti klastera.

Konačni klasteri i poslovna interpretacija:

Klaster	Naziv	Profil	Poslovno značenje
1	**Whales / Champions**	Nedavni, česti, vrlo visoka potrošnja	Korporativni ključni računi — razred s najvišim prihodom. Zaštiti odnos; preporuči nove kategorije oprezno.
3	**Active Small Buyers**	Nedavni, skromna frekvencija, skromna potrošnja	Zdrava jezgrena baza kupaca. Cross-sell kandidati s najvišom stopom pogodaka po kontaktu.
2	**Mid-Tier At Risk**	Umjerena nedavnost, umjerena potrošnja, opadajući angažman	Ciljevi za povratak. Personalizirani cross-sell može ih reaktivirati.
0	**Hibernating**	Dugo bez kontakta, niska frekvencija, niska potrošnja	Najveći rizik od odljeva. Jeftino reaktivirati, ali najniža očekivana vrijednost po ponudi.

`Cluster_name` je eksportiran u `data/processed/rfm_segments.csv` i konzumiran od strane i cross-sell preporučitelja (kao značajka) i up-sell modela (za rangiranje stavki uvjetovano klasterom).

4.2 Analiza tržišne košarice (Market-Basket)

Bilježnica: `notebooks/market_basket.ipynb`.

4.2.1 Odluka o granularnosti: Kupac × Kalendarski mjesec Prva intuicija je koristiti `Invoice\#` kao košaricu. Testirali smo to:

> **98,2% faktura sadrži samo jednu grupu proizvoda.** Fakture s više PG-ova čine 1,8% svih faktura — prerijetko da bi se producirala smislena asocijacijska pravila.

Kupčevi ritmi kupovine u B2B-u su PO-vođeni i tipično mjesečni (medijan razmaka između uzastopnih faktura ≈ 20 dana za ponovljene kupce). Redefiniranjem košarice kao **`CustomerID\+\YYYY-MM`** stopa košarica s više PG-ova raste na **27,5%** — dovoljno signala za Apriori/FP-Growth da pronađe pravila.

Ovo je namjerna, B2B-specifična metodološka odluka. U B2C maloprodajnom kontekstu, košarice na razini fakture bile bi pravi izbor.

4.2.2 Odluka o granularnosti: Grupa proizvoda, ne kod stavke `Item\Code` ima ~52.000 jedinstvenih vrijednosti; pravila na toj granularnosti imala bi gotovo nulti support i preučila bi se na šum. Product group (~30 vrijednosti) je prirodna razina preporuke — o njoj razmišlja tim prodaje i po njoj e-commerce stranica kategorizira. Bonus analiza na razini Item Code-a u bilježnici potvrdila je da je PG prava granularnost.

4.2.3 Algoritmi: Apriori i FP-Growth Oba algoritma pokrenuta su s `min_support=0.01`, `max_len=3`. Kao što se i očekivalo, producirali su **identične česte skupove stavki** (verificirano unutar bilježnice). FP-Growth je preferirani za performanse; Apriori se čuva zbog didaktičke jasnoće (antimonotonost koja opravdava podrezivanje).

4.2.4 Filtriranje pravila Pravila su filtrirana prema tri praga:

Metrika	Prag	Obrazloženje
Lift	> 2.0	Pravila barem 2× jača od slučajnosti — jasno ne-slučajne asocijacije
Confidence	> 0.30	Barem 30% vjerojatnost kupovine konsekventa uz dani antecedens
Conviction	> 1.3	Nesuglasje s pretpostavkom nezavisnosti — provjera robusnosti

Rezultat: 14 jakih asocijacijskih pravila (`data/processed/association_rules.csv`).

4.2.5 Stope ko-kupovine kao proširenje signala 14 čvrstih pravila pokriva samo ~0,6% svih usmjerenih PG-prema-PG parova. Za proširenje signala, izračunali smo i `P(PG_b\\TU\textbar{}\PG_a)` za **sve** opažene usmjerene parove (do 870 = 30 × 29). Ovo producira 27 značajki po (kupcu, kandidat-PG) paru u cross-sell preporučitelju:

- `max_copurchase_rate` — najjači signal ko-kupovine od bilo kojeg postojećeg PG-a kupca
- `mean_copurchase_rate` — prosječni signal ko-kupovine kroz sve postojeće PG-ove

To znači da cross-sell model ima i **značajke čvrstih pravila** (iz 14 pravila) i **značajke mekog signala** (iz 870 parova ko-kupovine).

4.3 Cross-Sell preporučitelj — model Kupac × Grupa proizvoda

Bilježnica: `notebooks/cross_sell_recommender.ipynb`.

4.3.1 Formulacija problema Raniji rad (`notebooks/archive/cross_sell_model.ipynb`) formulirao je cross-sell kao binarnu klasifikaciju na razini kupca: “hoće li ovaj kupac ikad cross-sell-ati?” To odgovara na pitanje, ali ne na korisno — ne govori API-ju *koji* proizvod preporučiti.

Produkcijski preporučitelj preformulira zadatak kao **predikciju po paru**:

> Za svaki (kupac, kandidat-grupa proizvoda koja nije kupljena u trening periodu), predvidi vjerojatnost da će kupac kupiti iz te grupe u 12-mjesečnom label window-u (periodu oznake).

Ovo producira **rangirani popis po kupcu** koji izravno mapira na API izlaz.

4.3.2 Konstrukcija matrice Za svakog kupca u trening periodu: - Uzmi skup PG-ova koje su već kupili u trening periodu (oni su isključeni — preporučujemo samo nove kategorije). - Za svaki drugi PG u katalogu, stvori red. - Ciljna varijabla = 1 ako je kupac kupio iz tog PG-a u label window-u, 0 inače.

Rezultat: ~257K (kupac, PG) parova, **0,34% stopa pozitivne klase** (≈ neravnoteža 290:1). Ova klasna neravnoteža temeljna je svojstvo problema: većina cross-sell mogućnosti ne konvertira u bilo kojoj danoj godini.

4.3.3 Inženjerstvo značajki — 27 značajki po paru Tri obitelji značajki:

Značajke kupca (15) — sve izračunate samo iz trening perioda: - Volumetrijske: `train_revenue`, `train_orders`, `train_items`, `train_n_groups` - Bihevioralne: `train_avg_gm`, `recency_days`, `tenure_days`, `order_frequency` - Kategorijalne (label-enkodirane): `region_enc`, `industry_enc`, `top_group_enc`, `cluster_enc` - RFM ocjene: `R_score`, `F_score`, `M_score`

Značajke grupe proizvoda (7): - `pg_n_customers`, `pg_avg_price`, `pg_avg_gm`, `pg_total_orders`, `pg_avg_revenue`, `pg_popularity`, `pg_enc`

Asocijacijske/ko-kupovne značajke (5): - Iz 14 čvrstih pravila: `rule_exists`, `rule_max_lift`, `rule_max_confidence` - Iz 870 ko-kupovnih parova: `max_copurchase_rate`, `mean_copurchase_rate`

4.3.4 Obrada klasne neravnoteže — SMOTE Neravnoteža 290:1 previše je ekstremna za samo `class_weight`. **SMOTE** s `sampling_strategy=0.1` primjenjuje se **samo na fold za treniranje** (koristeći `imblearn.pipeline.Pipeline` tako da fold za testiranje ostaje netaknut). Ovo povećava stopu pozitivne klase u foldovima za treniranje s 0,34% na ~9%, dovoljno za modele temeljene na stablima da pronađu čistu granicu odluke.

4.3.5 Usporedba modela Tri modela trenirana na istom skupu značajki s identičnim SMOTE-om:

Model	Test ROC-AUC	5-Fold CV ROC-AUC	Napomene
Logistic Regression	0.8654	—	Osnova — linearno po značajkama
Random Forest	0.9141	—	Hvata nelinearne interakcije
XGBoost	**0.9248**	**0.9291 ± 0.0055**	Najbolji — tijesno ograničena varijanca kroz foldove

5-fold unakrsna validacija koristi `GroupKFold` ključiran na `CustomerID` tako da svi parovi za zadanog kupca padaju u isti fold — sprječavajući leakage (curenje informacija) na razini kupca između treniranja i validacije.

Konfiguracija XGBoost-a:

```
n_estimators=300, max_depth=6, learning_rate=0.05,
subsample=0.8, colsample_bytree=0.8, random_state=42
```

XGBoost je odabran kao produkcijski model. Njegova `.pkl` datoteka sprema se u `models/recommender/recommender_xgb.pkl` i učitava API.

Naknadni eksperiment s kliznim prozorom u §13 bilježnice ponovo je trenirao XGBoost na tri dodatna povijesna prozora (srp–pro 2018, lis 2018–ožu 2019, sij–lip 2019) naslagana na osnovni trening period. Prošireno treniranje **nije nadmašilo** osnovni model — AUC je ostao na istoj razini — pa je implementirani `recommender_xgb.pkl` pre-rolling-window, 27-značajkasti XGBoost izvještavan gore (AUC 0.9248). Kod kliznog prozora čuva se u bilježnici radi reproducibilnosti ali nije dio produkcijskog artefakta.

4.3.6 Razina 2 — Prijedlozi stavki unutar preporučenog PG-a XGBoost model rangira **grupe proizvoda**, ali API vraća i **specifične kodove stavki** unutar svake preporučene grupe. Ovo je "Razina 2" pretraživanje — ponovo koristi popularnost stavki uvjetovanu klasterom iz up-sell bilježnice (bez premium-only filtera) za preporuku najpopularnijih stavki u preporučenom PG-u **među kupcima u istom klasteru**.

To znači da Whale kupac i Hibernating kupac dobivaju isti skup preporučenih PG-ova ali potencijalno različite prijedloge stavki unutar svakog PG-a.

4.4 Up-Sell model

Bilježnica: `notebooks/upsell_model.ipynb`.

4.4.1 Klasifikacija razreda — Standard vs Premium Za svaki `(Product\group, \Item\Code)`, izračunaj prosječnu cijenu stavke kroz trening period. Zatim unutar svakog PG-a uzmi **medijan tih prosjeka stavki**. Stavke na medianu ili iznad njega označavaju se kao **`premium`**; ispod su **`standard`**.

Rezultat: 38.734 razvrstane stavke, od kojih je 19.382 premium (gornja polovica svakog PG-a prema prosjeku cijene stavke).

PG medijan prosjeka stavki — a ne sirovih linijskih cijena — odabran je kako jeftine stavke s iskrivljenim volumenom ne bi snizile prag.

4.4.2 Identifikacija up-sell ciljeva Za svaki (kupac, PG) par, izračunaj kupčevu prosječnu plaćenu cijenu u tom PG-u za vrijeme treniranja. Ako je njihov prosjek **ispod PG medijana**, oni su up-sell cilj — kupuju u kategoriji ali po cijenama nižeg razreda.

Rezultat: 6.458 ciljnih (kupac, PG) parova kroz 4.993 jedinstvena kupca.

Ovo je skup up-sell kandidata. Imajte na umu da API također obrađuje slučaj "trenutna stavka je već premium" vraćanjem bez preporuke.

4.4.3 Popularnost premium stavki uvjetovana klasterom Za svaku kombinaciju `(Cluster_name,\Product\group,\Item\Code)` gdje je stavka `premium`:

```
confidence = (# kupaca u klasteru koji su kupili ovu stavku u ovom PG-u)
             / (# kupaca u klasteru koji su kupili išta u ovom PG-u)
```

Filter `n_buyers\≥\2` uklanja šum s jednom kupovinom. (Jedan poznati rubni slučaj: PG `SF001` ima samo jednu stavku, pa njegova rangiranja degeneriraju u "kupi jedinu dostupnu stavku" — zabilježeno u bilježnici.)

Ovo daje rangiranje "koje premium stavke kupuju moji vršnjaci?" po klasteru, što je personalizacijski sloj za up-sell preporuke.

4.4.4 Generiranje preporuka Za svaki up-sell cilj (kupac × PG): 1. Pronađi kupčev klaster. 2. Iz popularnosti premium stavki tog klastera u ciljnom PG-u, ispusti stavke koje je kupac već kupio. 3. Uzmi top-K (K=5) prema confidence-u.

Rezultat: 27.744 up-sell preporuke pokrivajući 4.843 kupaca kroz 26 grupa proizvoda.

---

5. Evaluacija

5.1 Evaluacija segmentacije

- **Veličine klastera** su dobro uravnotežene (nijedan klaster ne guta populaciju, nijedan nije degeneriran). Sva četiri klastera popunjena su s stotinama do tisuća kupaca.
- **Snake plot** (srednja vrijednost skalirane R, F, M po klasteru) pokazuje jasno različite profile — Whales su visoko na F i M s niskim R; Hibernating je zrcalna slika; dva srednja klastera jasno su odvojena po nedavnosti.
- **Interaktivni 3D plot** (`visualization/clusters_3d.html`) vizualno potvrđuje da četiri klastera zauzimaju distinktne regije log-skaliranog RFM prostora.
- **Silhouette score** pri K=4 bio je viši nego pri K=3 i kompetitivan s K=5/6 uz daleko bolju interpretabilnost za poslovne korisnike.

Klasteri nisu samo statistički odvojivi — mapiraju se na prepoznatljive poslovne arhetipove (ključni računi, zdrava jezgra, u riziku, neaktivni), što je teži kriterij za zadovoljiti.

5.2 Evaluacija cross-sell preporučitelja

5.2.1 Primarna metrika: ROC-AUC

Postavka	Ocjena
Test set ROC-AUC (XGBoost)	**0.9248**
5-fold GroupKFold CV ROC-AUC	**0.9291 ± 0.0055**
Random Forest test AUC	0.9141
Logistic Regression test AUC	0.8654

Interval unakrsne validacije je uzak (±0.005), što znači da je AUC stabilan kroz različite podskupove kupaca — nije slučajnost iz jedne povoljne raspodjele trening/test.

5.2.2 Sekundarna metrika: Precision@5 Za svakog kupca u test skupu, uzmi prvih 5 preporučenih PG-ova modela i izračunaj udio koje je kupac stvarno kupio u label window-u.

- **Prosječni Precision@5: 0,38%**
- **Slučajna osnova (neravnoteža 290:1): 0,34%**

Poboljšanje u odnosu na slučajno je malo u apsolutnim iznosima — ovo je svojstvo osnovne klasne neravnoteže i dugorepe prirode B2B cross-sell-a, *ne* neuspjeh modela. AUC je odgovarajuća metrika za sustave rangiranja s ekstremnom neravnotežom; Precision@5 se izvještava kao provjera zdravog razuma, a ne kao glavna figura.

5.2.3 Važnost značajki (Random Forest, kvalitativno) Najjače značajke grupiraju se u tri grupe, otprilike ovim redoslijedom važnosti:

1. **Ko-kupovni signal** (`max_copurchase_rate`, `mean_copurchase_rate`) — proširenje 14 čvrstih pravila na cijeli krajolik od 870 parova imalo je visoki učinak.
2. **Bihevioralne značajke kupca** (`train_revenue`, `train_orders`, `train_n_groups`, `recency_days`).
3. **Bazne stope grupe proizvoda** (`pg_popularity`, `pg_n_customers`).

Značajke čvrstih pravila (`rule_exists`, `rule_max_lift`, `rule_max_confidence`) su korisne ali pokrivaju premalo parova da bi dominirale.

5.2.4 Metodologija validacije — Zašto vremenski hold-out Nasumične raspodjele na (kupac, PG) parovima dozvolile bi modelu da vidi jedan PG za kupca u treniranju i predvidi drugi za istog kupca u testiranju — to nije stvarni cross-sell scenarij. **Vremenski hold-out** (trening < 2019-07-01, label 2019-07-01 → 2020-07-01) jedini je način da se iskreno odgovori "s obzirom na ono što znam o kupcu danas, što će kupiti u sljedećih 12 mjeseci?" `GroupKFold` na `CustomerID` je analog unakrsne validacije istog načela.

5.3 Evaluacija up-sell modela

Validacija je teža jer ne postoji direktni signal "je li ovaj kupac prihvatio up-sell?". Koristimo **proxy naprednog rasta cijene**:

> Ako je kupac bio cilj u trening periodu (kupuje ispod PG medijana) i ponovo se pojavi u label window-u, je li njegova prosječna cijena u tom PG-u porasla?

Ključni brojevi (iz `models/upsell/upsell_meta.json`):

Metrika	Vrijednost	Interpretacija
Ciljevi s podacima iz label window-a	3.720 / 6.458 (59,9%)	Pokrivenost proxy metrike
Prosječni rast cijene (label vs. trening)	**+$35,62**	Ciljevi su u prosjeku platili više u sljedećih 12 mjeseci
Udio s pozitivnim rastom	**44,25%**	Gotovo polovica pomakla se gore u cijeni unutar istog PG-a
Udio koji je prešao u premium razred	**7,61%**	Čvrsti signal — stvarno su kupili premium stavku

Ovi brojevi se prikazuju iskreno s njihovim ograničenjima:

- **Nema kontrolne grupe.** Ne možemo odvojiti učinak modela od prirodnog rasta cijena na tržištu. Bilježnica to označava i predlaže izračunavanje iste stope migracije na slučajnom uzorku ne-ciljanih kupaca kao provjeru zdravog razuma.
- **Pokrivenost je 60%, ne 100%.** 40% ciljeva koji se ne pojave u label window-u ne pridonose ni dokazu ni protuargumentu.

Zajedno gledano: **up-sell ciljanje jasno identificira segment čije se cjenovno ponašanje kreće prema gore u naprednom prozoru.** Je li to kretanje kauzalno ili korelacijsko zahtijeva A/B test; proxy je dovoljno jak signal da opravda implementaciju (deployment) preporučitelja.

5.4 Kvaliteta preporuka API-ja

Osim metrika modela, kvaliteta preporuka API-ja vidljiva je na dva načina:

1. **Pokrivenost.** S 9.017 poznatih kupaca učitanih u memoriju i 30 grupa proizvoda, svaki postojeći kupac uvijek prima 5 preporuka. Cold-start (nepoznati `CustomerID` ili nije proslijeđen `customer_id`) vraća se na medijane populacije i još uvijek producira rangirani izlaz.
2. **Personalizacija.** Dva kupca u različitim klasterima koji prime isti preporučeni PG vide različite liste `items` — vođene `upsell_item_popularity_all.csv` filtriranim prema `Cluster_name`.

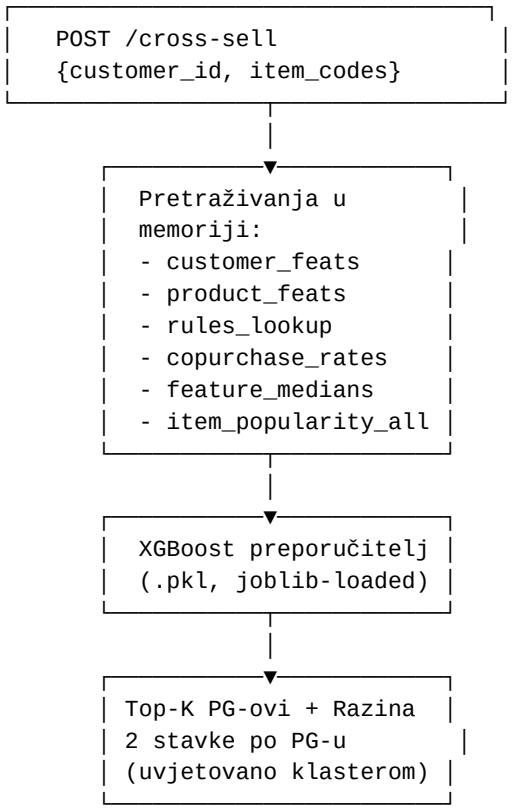
Živa latencija (nakon toplog pokretanja) je ispod sekunde po pozivu jer se svaki artefakt učitava u rječnik memorije pri pokretanju; pri obradi zahtjeva ne dolazi do čitanja s diska.

---

6. Implementacija (Deployment)

6.1 Arhitektura

Implementacija je **jednoprocesna FastAPI aplikacija** (`api/main.py`) koja učitava sve modelske artefakte i tablice za pretraživanje u memoriju pri pokretanju putem `lifespan` hook-a.



6.2 Endpoint-točke

`GET\/health` Provjera zdravog razuma da je model učitan i da su značajke kupaca u memoriji:

```
{ "status": "ok", "model_loaded": true, "known_customers": 9017, "layer2_available": true }
```

`POST\/cross-sell` **Ulaz** | Polje | Tip | Obavezno | Ponašanje ako nedostaje | |—|—|—|—| | `customer_id` | int | Ne | Vraća se na medijane značajki populacije | | `item_codes` | list[str] | Ne | Nema ko-kupovnog / asocijacijskog signala |

Logika 1. Učitaj kupčeve pohranjene značajke (ili medijan kao zamjena) i `Cluster_name`. 2. Mapiraj proslijeđene `item_codes` na njihove PG-ove putem pretraživanja `item_tiers`. 3. Izgradi skup kandidata: svi PG-ovi **minus** oni koje kupac već kupuje **minus** PG-ovi iz trenutne narudžbe. 4. Za svaki kandidat PG, izgradi red s 27 značajki u trenutku zahtjeva (značajke pravila i ko-kupovne značajke ovise o živim `item_codes`, pa se ne računaju unaprijed). 5. Ocijeni s XGBoost-om, sortiraj po vjerojatnosti, uzmi top 5. 6. Za svaki top-K PG, pronađi Razinu 2 stavki u kupčevom klasteru.

Izlaz

```
{
  "customer_id": 12345,
  "recommendations": [
```

```
    {
      "product_group": "PC016",
      "confidence": 0.4642,
      "items": [
        {"item_code": "BOE001-TY8.375", "confidence": 0.1098, "avg_price": 6.02}
      ]
    }
  ]
}
```

`confidence` na PG-u je XGBoost-om predviđena vjerojatnost da će kupac kupiti iz te grupe. `confidence` na svakoj stavci je udio kupaca u klasteru koji kupuju tu stavku unutar PG-a.

`POST\/up-sell` **Ulaz** | Polje | Tip | Obavezno | |—|—|—| | `customer_id` | int | Ne (preskače personalizaciju klastera ako nedostaje) | | `item_codes` | list[str] | Da |

Logika Za svaki ulazni kod stavke: 1. Pronađi razred i PG stavke (preskoči ako nepoznat). 2. Ako je stavka već `premium`, preskoči — nema čega up-sell-ati. 3. Filtriraj `upsell_popularity` na isti PG, zatim opcionalno na kupčev klaster (ako je klaster pronađen; inače poslužuj bez klastera). 4. Uzmi top-K premium alternativa prema confidence-u, isključujući stavku koju kupac već kupuje.

Izlaz

```
{
  "customer_id": 12345,
  "recommendations": [
    {
      "current_item": "03650",
      "product_group": "PC001",
      "current_tier": "standard",
      "current_avg_price": 0.0,
      "premium_alternatives": [
        {"item_code": "2158", "confidence": 0.0495, "avg_price": 78.99}
      ]
    }
  ]
}
```

6.3 Cold-Start ponašanje

Oba endpoint-a prihvaćaju nedostajući `customer_id` (B2B walk-up slučaj ili kupac koji dolazi prvi put):

- **Cross-sell:** značajke se vraćaju na `feature_medians.json` (medijani populacije iz treniranja); Razina 2 stavki specifičnih za klaster vraća se na rangiranje neovisno o klasteru. Rezultat: razborito “što bi prosječni kupac sljedeće htio?” odgovor.
- **Up-sell:** personalizacija klastera se preskače i vraća se rangiranje premium stavki unutar PG-a neovisno o klasteru.

6.4 Pokretanje u produkciji

Referentna naredba (razvojna okolina):

```
conda activate lumen-ds
uvicorn api.main:app --host 0.0.0.0 --port 8000 --reload
```

Napomene o produkcijskom implementaciji:

- **Pretpostavka jednog radnika.** `state:\dict` je unutar procesa; implementacija s više radnika (Gunicorn) zahtijevala bi ili dijeljenu cache ili učitavanje istih artefakata po radniku.

- **Nema autentikacije ni ograničenja brzine.** Oba endpoint-a su otvorena po dizajnu (API je interan). Dodaj autentikaciju na razini gatewaya ako je API izložen izvan mreže tvrtke.
- **Nema verzioniranja modela osim `model_meta.json`.** Kada se modeli ponovo treniraju, meta JSON se prepisuje — nema automatskog zapisa koji je hash dataseta producirao koji `.pkl`.
- **Zahtjevi API-ja su verzijski fiksirani** (`api/requirements.txt`) — okruženje bilježnice dokumentirano je u README/Run Book-u.

6.5 Reproducibilnost

Svaki korak u pipelineu koristi fiksne seedove i determinističke datume raspodjele:

Parametar	Vrijednost	Gdje je postavljen
Nasumični seed	42	Svi sklearn/XGBoost/SMOTE konstruktori
Granična vrijednost treniranja	2019-07-01	Bilježnice cross-sell, up-sell
Kraj label window-a	2020-07-01	Bilježnice cross-sell, up-sell
RFM snapshot	2020-07-01	Segmentacija kupaca
K (klasteri)	4	Segmentacija kupaca
SMOTE strategija	0.1	Cross-sell preporučitelj
Top-K	5	Oba endpoint-a, obe bilježnice za treniranje

Manji izvor varijance — XGBoost `n_jobs=-1` može producirati ±0.002 AUC varijaciju zbog nedeterminističke akumulacije decimalnih zareza u paralelu — dokumentiran je u Run Book-u i ne utječe na poslovne odluke ni rangiranja.

Dodatak — Sažetak izlaza pipelinea

Bilježnica	Primarni izlaz	Koristi ga
`01\data_cleaning`	`data/processed/data_clean_final.csv`	Svaka nizvodna bilježnica
`02\customer_segmentation`	`data/processed/rfm_segments.csv`	Cross-sell preporučitelj, up-sell model
`03\market_basket`	`data/processed/association_rules.csv`	Cross-sell preporučitelj
`04\cross_sell_recommender`	`models/recommender/*.pkl`, `data/processed/recommender/*.csv`, `feature_medians.json`	API `/cross-sell`
`05\upsell_model`	`data/processed/upsell/*.csv`, `models/upsell/upsell_meta.json`	API `/up-sell` i `/cross-sell` Razina 2
`archive/encoding_and_feature_engineering`	`customer_features.csv`, `data_clean_enc_fe.csv`, `invoice_items.csv`	Samo istraživački — ne konzumira ga produkcijski pipeline (vidi §3.7)
`archive/cross_sell_model`	`models/cross_sell/*.pkl`	Samo istraživački — zamijenjeno produkcijskim cross-sell preporučiteljem (vidi §4.3.1)

Ovaj dokument prati README.md (brzi start i postavke okruženja) i Run Book (operativni postupci i rješavanje problema).